Projet Cassiopée 2026 – Hôpital Foch
développement d'un model IA pour la détection d'anomalies lors de l'acquisition de données de spectrométrie de masse pour l'analyse de l'air expiré

Table des matières

1- Contexte : 2
2- Les données de spectre de masse 2
3- Exemple de fichier avec anomalie : 3
A – Décalage du spectre en masse : 3
b- Intensité du signal faible 4
c- Autres exemples 6
4- Description du jeux données 7
5- Bibliographie 7

1- Contexte :

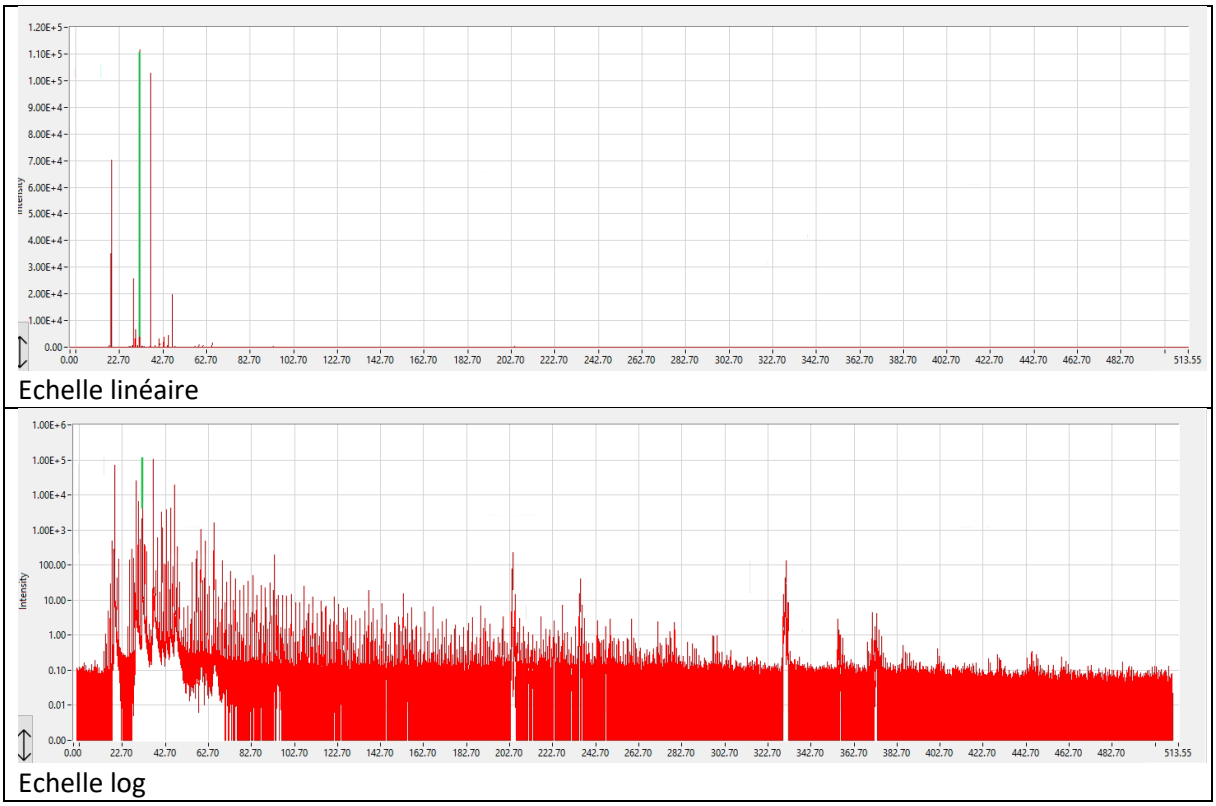
L'hôpital Foch conduit un programme de recherche, qui repose sur l'analyse des composés organiques volatils (COV) contenus dans l'air expiré dans le but de diagnostiquer simplement et rapidement des maladies ou de suivre la réponse aux médicaments. Un spectromètre de masse, PTR-TOF-MS (Herbig et al., 2009)) est utilisé pour analyser en temps réel les COV présents dans l'air expiré (Grassin-Delyle et al., 2021; Roquencourt et al., 2023, 2022).

Avant chaque acquisition, une étape importante de calibration (Cappellin et al., 2011a, 2011b) de l'instrument doit être réalisée, et une validation visuelle des données brutes par un expert est actuellement indispensable pour garantir la qualité des acquisitions. Cependant, dans le cadre de certains protocoles cliniques menés sur plusieurs centres, la présence systématique d'un expert pour valider chaque acquisition n'est pas réalisable.

L'objectif de ce projet est de développer une méthode d'Intelligence Artificielle capable de prédire la fiabilité d'une analyse de spectrométrie de masse à partir d'une base de données interne.

2- Les données de spectre de masse

Un spectre de masse est un vecteur correspondant à l'intensité du signal pour des masses allant de 0 à 500 Da.



Echelle linéaire

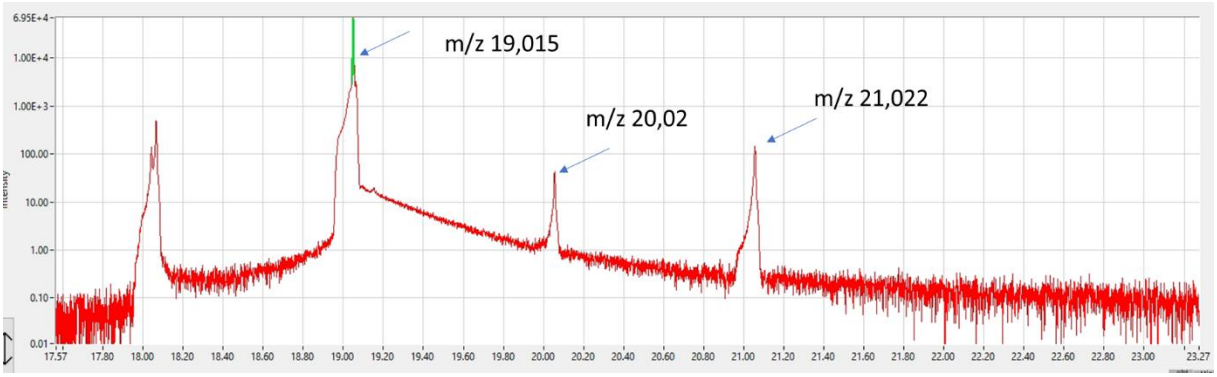
Echelle log

Le spectre de masse obtenu lors d'une acquisition d'air ambiant (background) présente une forme usuelle, caractérisée notamment par :

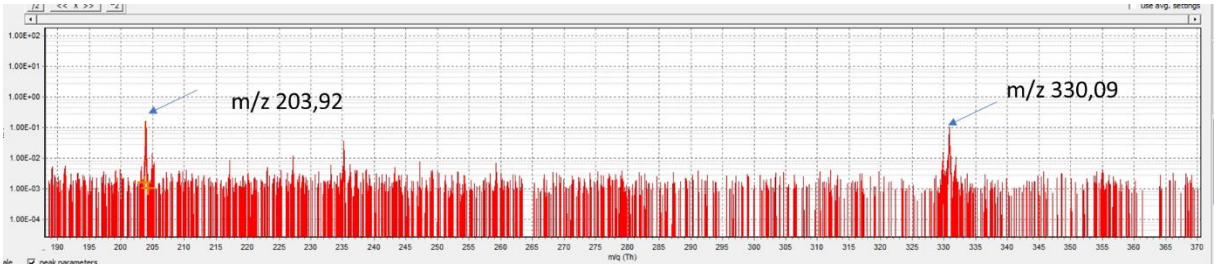
- une intensité minimale attendue,
- une calibration en masse correcte, avec la position exacte de pics connus.

Il est difficile de définir des seuils fixes pour ces conditions, car elles peuvent varier, et la liste des anomalies possibles est non exhaustive.

On représente généralement les spectres en échelle logarithmique : les pics les plus intenses apparaissent pour des masses < 30 Da. Le pic majoritaire est m/z 19 (H_3O^+), suivi de deux isotopes aux masses m/z 20 et 21.



Deux pics sont également majoritaires après m/z 200.

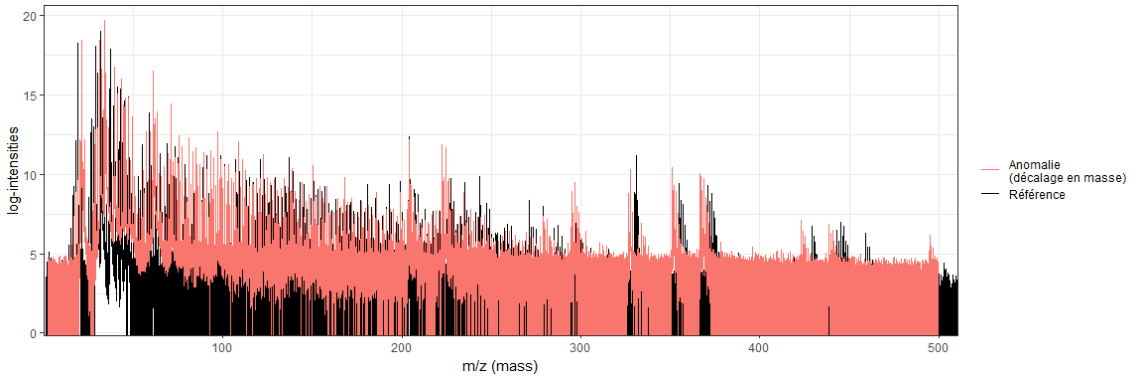


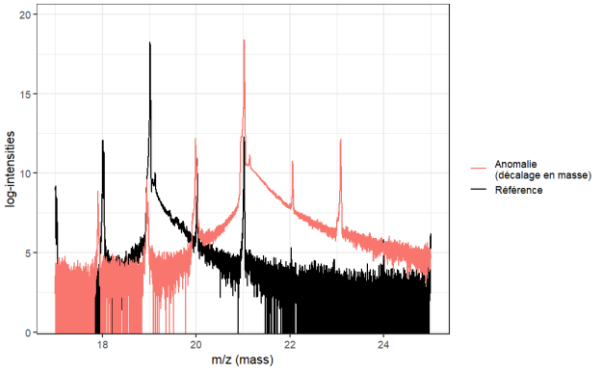
L'objectif du projet est d'évaluer si un modèle d'IA (type Deep Learning) permet d'identifier très rapidement les spectres anormaux à partir de l'apprentissage d'un grand nombre de spectres normaux, et de déterminer si ces algorithmes surpassent des contrôles classiques tels que les seuils d'intensité ou la calibration standard.

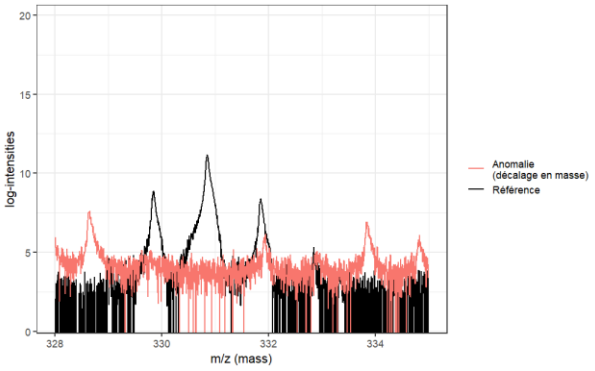
3- Exemple de fichier avec anomalie :

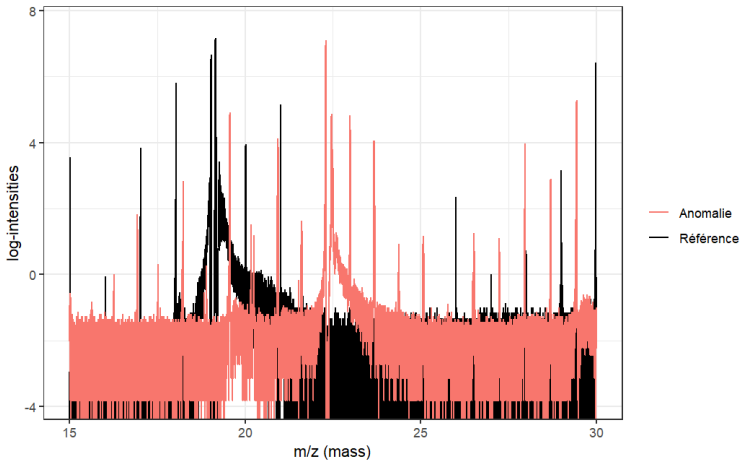
Voici des exemples d'anomalies de spectres. La liste n'est pas exhaustive, car toutes les erreurs n'ont pas été répertoriées, et elles sont souvent corrigées manuellement.

A – Décalage du spectre en masse :

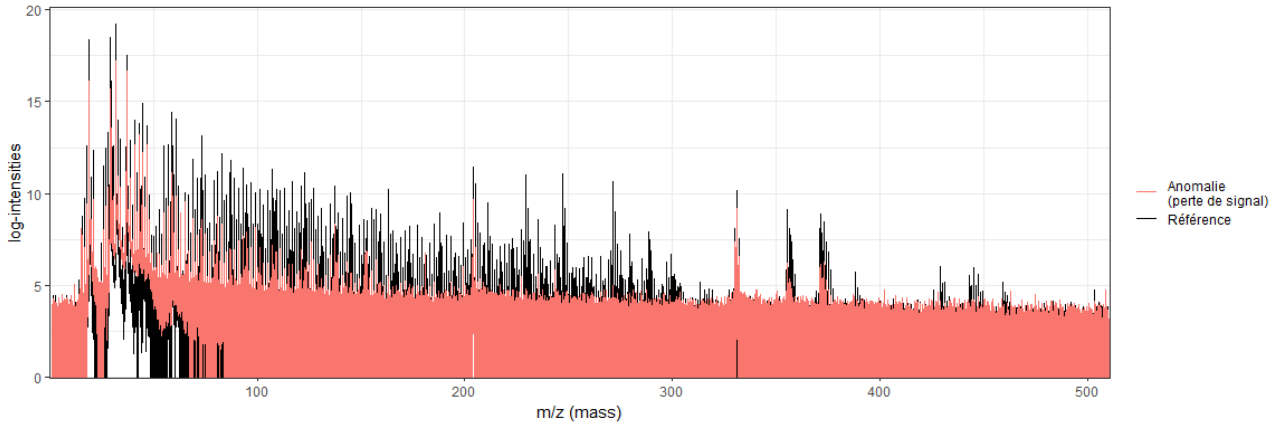


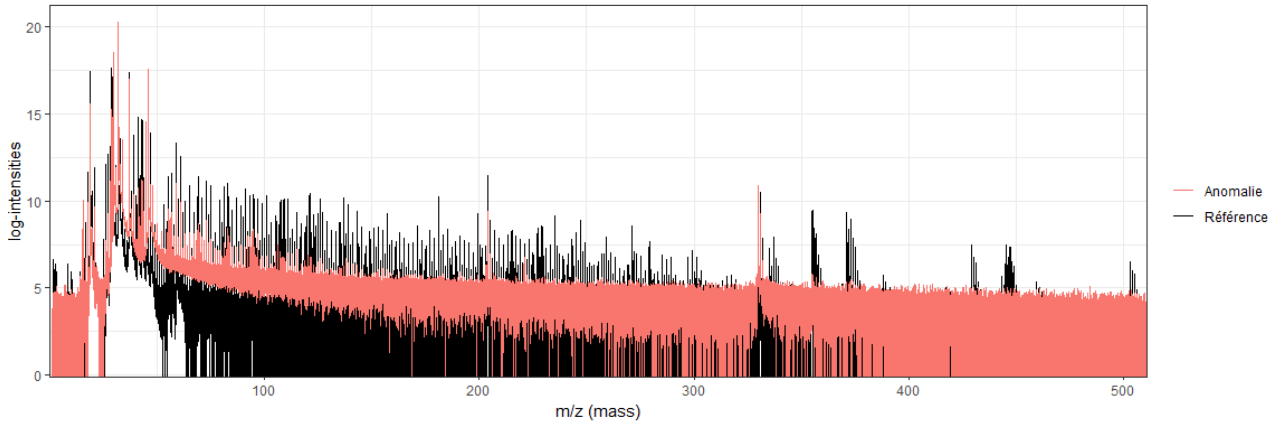


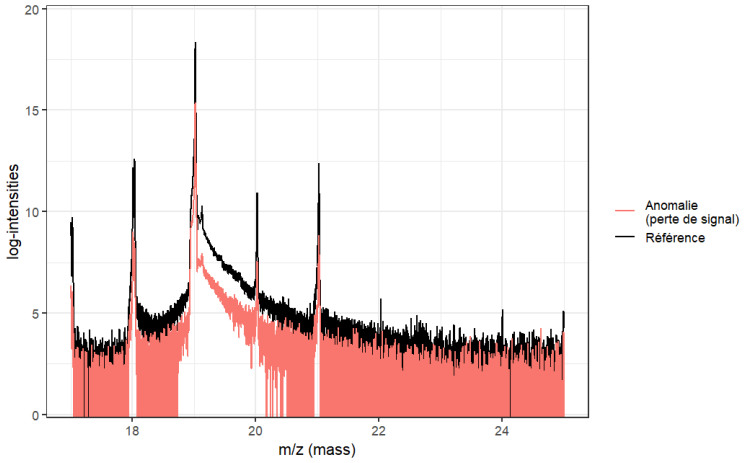


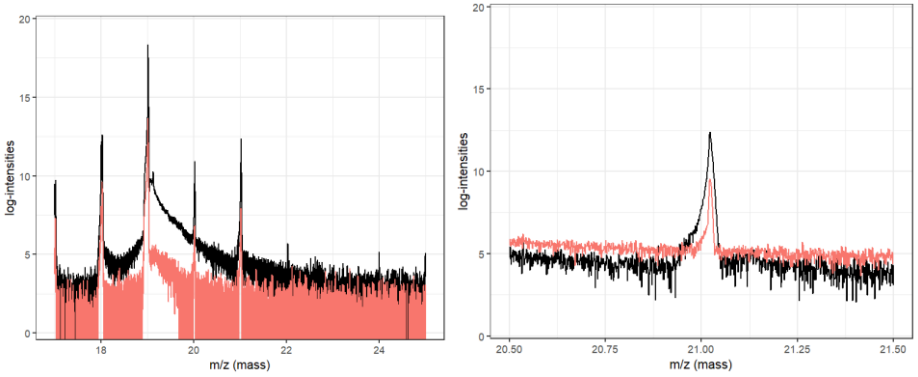


b- Intensité du signal faible

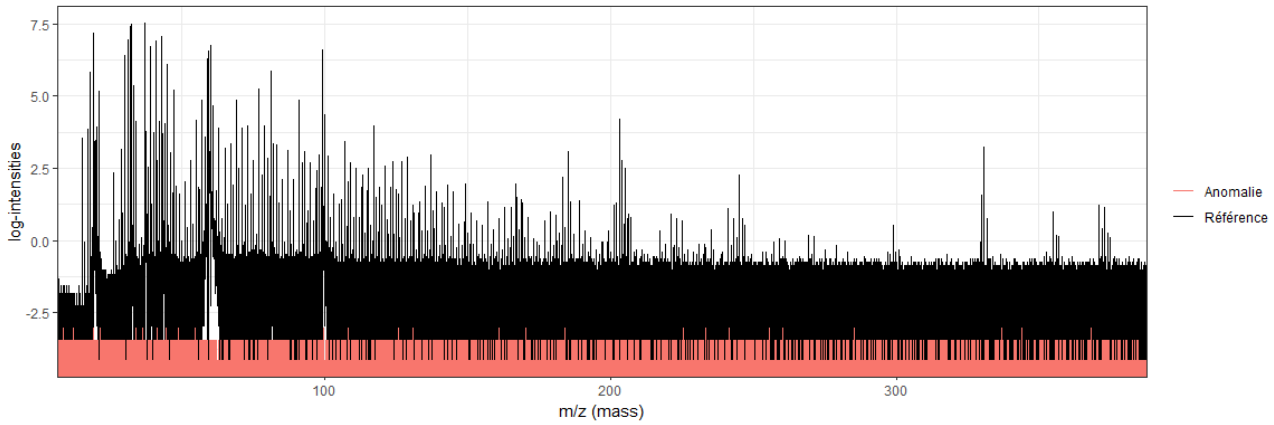

log-intensities
m/z (mass)
Anomalie
(perte de signal)
Référence


log-intensities
m/z (mass)
Anomalie
Référence


log-intensities
m/z (mass)
Anomalie
(perte de signal)
Référence

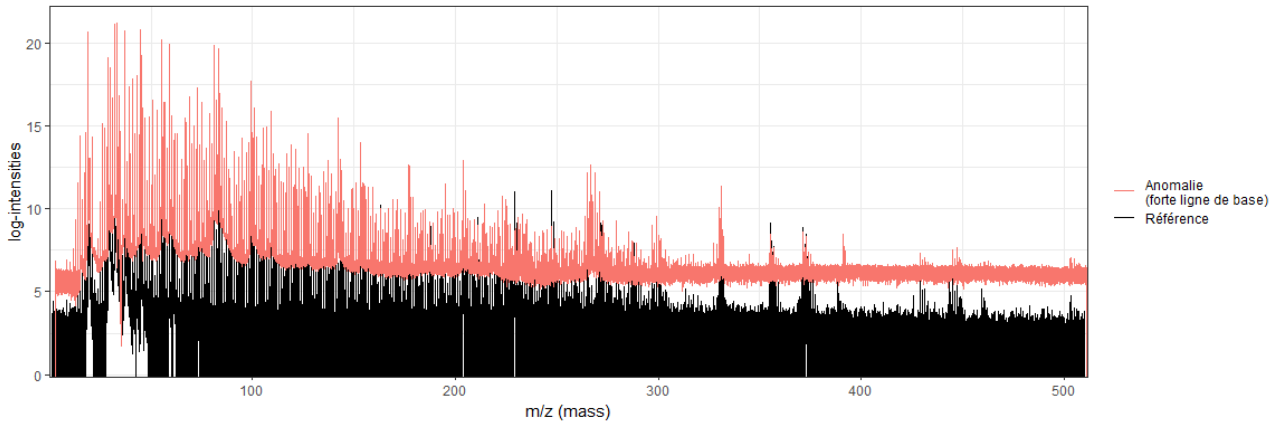

log-intensities
m/z (mass)
log-intensities
m/z (mass)

Pas de signal du tout:

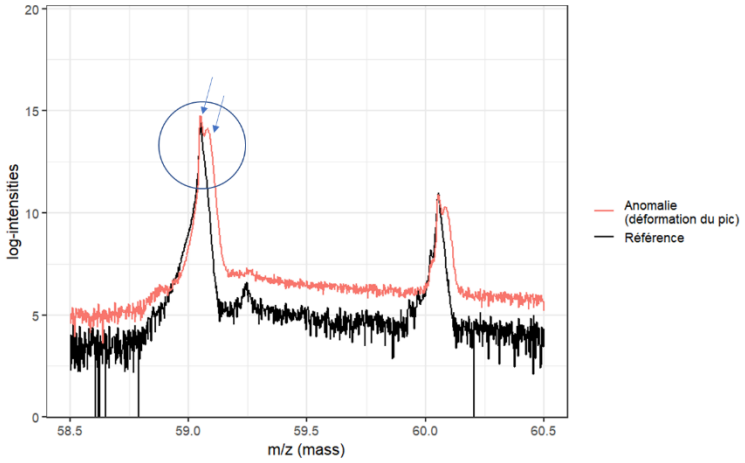


c- Autres exemples

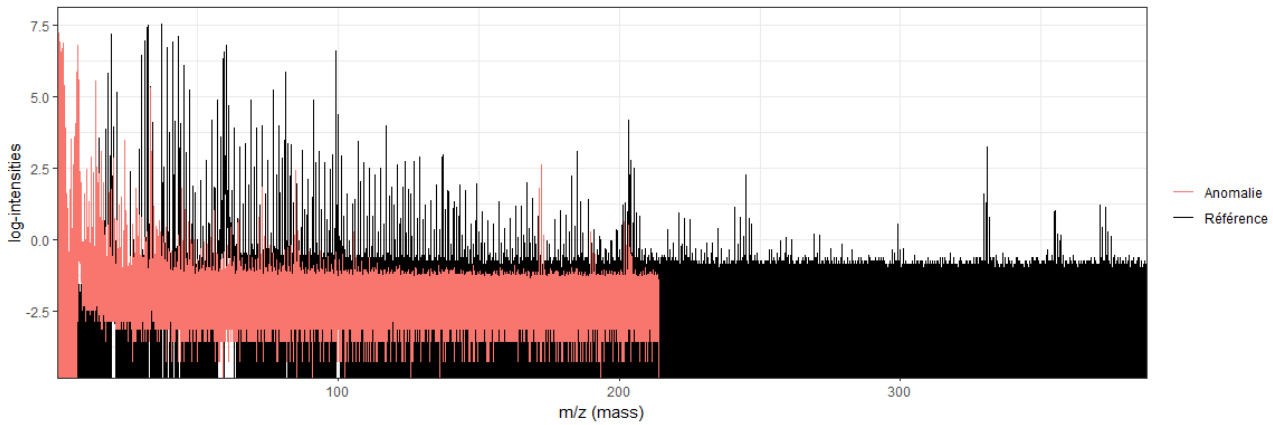
- Très forte ligne de base du système :



- Tous les pics du spectre ont une forme « dédoublé » :



- Exemple de décalage en masse extrême :



4- Description du jeux données

Les spectres sont au format CSV : la première colonne contient les valeurs de masse et la deuxième les intensités. Il est conseillé de transformer les intensités en échelle logarithmique (à tester).

- Les données du dossier **« reference spectrum »** correspondent aux spectres d'air ambiant (background) considérés comme « normaux ».
- Les données du dossier **« anomalies »** correspondent aux spectres utilisés pour les exemples d'anomalies de la section précédente, classés par type.
- Il sera possible par la suite d'en simuler (à partir de spectres normaux ou directement avec l'instrument si nécessaire).

5- Bibliographie

Cappellin, L., Biasioli, F., Granitto, P.M., Schuhfried, E., Soukoulis, C., Costa, F., Märk, T.D., Gasperi, F., 2011a. On data analysis in PTR-TOF-MS: From raw spectra to data mining. Sens. Actuators B Chem. 155, 183–190. https://doi.org/10.1016/j.snb.2010.11.044

Cappellin, L., Biasioli, F., Schuhfried, E., Soukoulis, C., Märk, T.D., Gasperi, F., 2011b. Extending the dynamic range of proton transfer reaction time-of-flight mass spectrometers by a novel dead time correction: Extending the dynamic range of PTR-TOF-MS. Rapid Commun. Mass Spectrom. 25, 179–183. https://doi.org/10.1002/rcm.4819

Grassin-Delyle, S., Roquencourt, C., Moine, P., Saffroy, G., Carn, S., Heming, N., Fleuriet, J., Salvator, H., Naline, E., Couderc, L.-J., Devillier, P., Thévenot, E.A., Annane, D., 2021. Metabolomics of exhaled breath in critically ill COVID-19 patients: A pilot study. EBioMedicine 63, 103154. https://doi.org/10.1016/j.ebiom.2020.103154

Herbig, J., Müller, M., Schallhart, S., Titzmann, T., Graus, M., Hansel, A., 2009. On-line breath analysis with PTR-TOF. J. Breath Res. 3, 027004. https://doi.org/10.1088/1752-7155/3/2/027004

Roquencourt, C., Grassin-Delyle, S., Thévenot, E.A., 2022. ptairMS: real-time processing and analysis of PTR-TOF-MS data for biomarker discovery in exhaled breath. Bioinformatics 38, 1930–1937. https://doi.org/10.1093/bioinformatics/btac031

Roquencourt, C., Salvator, H., Bardin, E., Lamy, E., Farfour, E., Naline, E., Devillier, P., Grassin-Delyle, S., 2023. Enhanced real-time mass spectrometry breath analysis for the diagnosis of COVID-19. ERJ Open Res.